Universidad de San Carlos de Guatemala

Facultad de Ingeniería

Sistemas de Bases de Datos 2



Informe Técnico

Integrante	Carnet
José Sebastián Pirir Romero	202300335
Pablo Josue Sosa Antonio	202000680
Francisco Gerardo Castillo Sagastume	202300653

Grupo 19

Sección: B

Análisis inicial

Recursos:

lenguaje python, fuentes csv y pandas.

Fuente 1 (carpeta clean-data archivo result):

Shape: (308408, 11)

Columnas: ['year', 'type', 'discipline', 'event', 'as', 'athlete_id', 'noc', 'team', 'place', 'tied', 'medal']

--- Valores nulos

---	nulos	porcentaje
year	2601	0.84
type	2601	0.84
discipline	1	0.00
noc	1	0.00
team	186694	60.53
place	25215	8.18
medal	264269	85.69

Fuente 1 (carpeta clean-data archivo noc_regions):

Shape: (230, 3)

Columnas: ['NOC', 'region', 'notes']

--- Valores nulos

---	nulos	porcentaje
region	3	1.30
notes	209	90.87

Fuente 1 (carpeta clean-data archivo populations):

Shape: (266, 66)

Columnas: ['Country Name', 'Country Code', '1960', '1961', '1962', '1963', '1964', '1965', '1966', '1967', '1968', '1969', '1970', '1971', '1972', '1973', '1974', '1975', '1976', '1977', '1978', '1979', '1980', '1981', '1982', '1983', '1984', '1985', '1986', '1987', '1988', '1989', '1990', '1991', '1992', '1993', '1994', '1995', '1996', '1997', '1998', '1999', '2000', '2001', '2002', '2003', '2004', '2005', '2006', '2007', '2008', '2009', '2010', '2011', '2012', '2013', '2014', '2015', '2016', '2017', '2018', '2019', '2020', '2021', '2022', '2023']

--- Valores nulos

---	nulos	porcentaje
1960	2	0.75
1961	2	0.75
1962	2	0.75
1963	2	0.75
1964	2	0.75
...	...	...

Fuente 1 (carpeta clean-data archivo bios):

Shape: (145500, 10)

Columnas: ['athlete_id', 'name', 'born_date', 'born_city', 'born_region', 'born_country', 'NOC', 'height_cm', 'weight_kg', 'died_date'

--- Valores nulos ---

	nulos	porcentaje
born_date	1807	1.24
born_city	34592	23.77
born_region	34592	23.77
born_country	34592	23.77
NOC	1	0.00
height_cm	38849	26.70
weight_kg	43430	29.85
died_date	111560	76.67

Fuente 2 (archivo athlete_events):

Forma: (271116, 15)

Columnas: ['ID', 'Name', 'Sex', 'Age', 'Height', 'Weight', 'Team', 'NOC', 'Games', 'Year', 'Season', 'City', 'Sport', 'Event', 'Medal']

--- Valores nulos

---	nulos	porcentaje
age	9474	3.49
height	60171	22.19
weight	62875	23.19
medal	231333	85.33

Fuente 3 (archivo olympics_dataset):

Forma: (252565, 11)

Columnas: ['player_id', 'Name', 'Sex', 'Team', 'NOC', 'Year', 'Season', 'City', 'Sport', 'Event', 'Medal']

--- Valores nulos por columna

--- No hay nulos

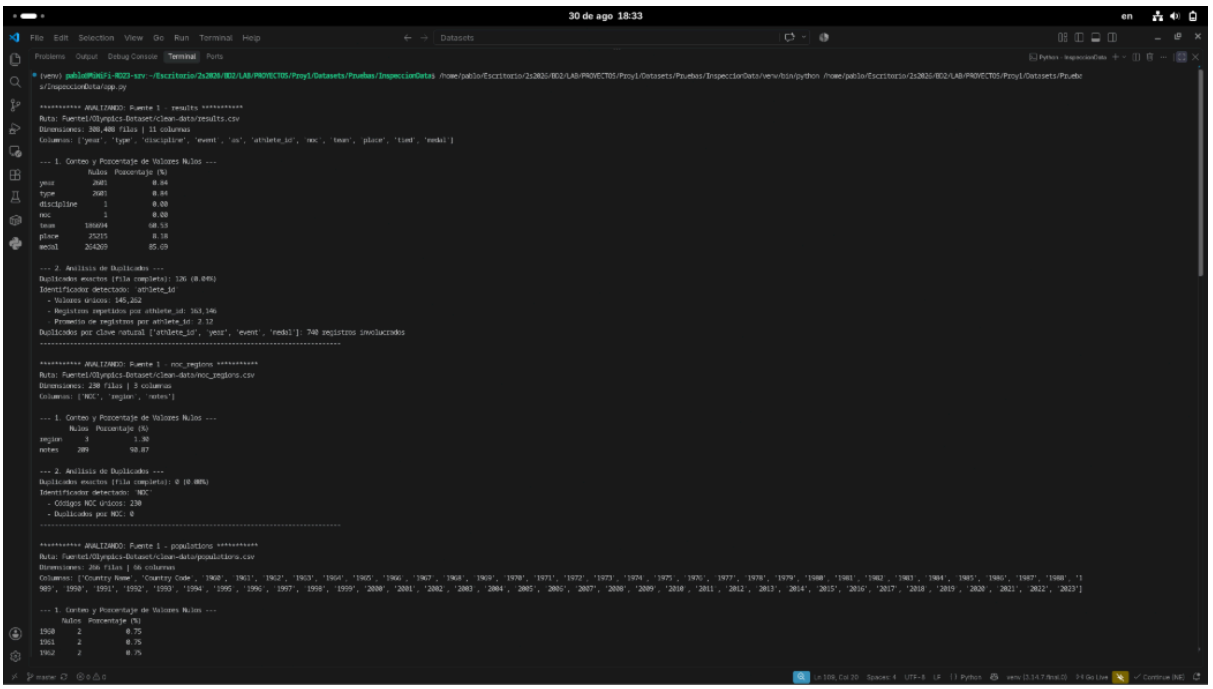
Fuente 4 (archivo athlete_events):

Forma: (271116, 15)

Columnas: ['id', 'name', 'sex', 'age', 'height', 'weight', 'team', 'noc', 'games', 'year', 'season', 'city', 'sport', 'event', 'medal']

--- Valores nulos por columna

---	nulos	porcentaje
age	9474	3.49
height	60171	22.19
weight	62875	23.19
medal	231333	85.33



Tablas modelo inicial

Region

- PK: noc_code
- country_name
- region

Edicion_Juego

- PK: id
- year
- season
- games_name
- city
- FK: noc_code

Disciplina

- PK: id
- sport
- event_name

Atleta

- PK: id
- full_name
- sex
- born_date
- born_city
- born_country
- height_cm
- weight_kg
- died_date
- FK: noc_code

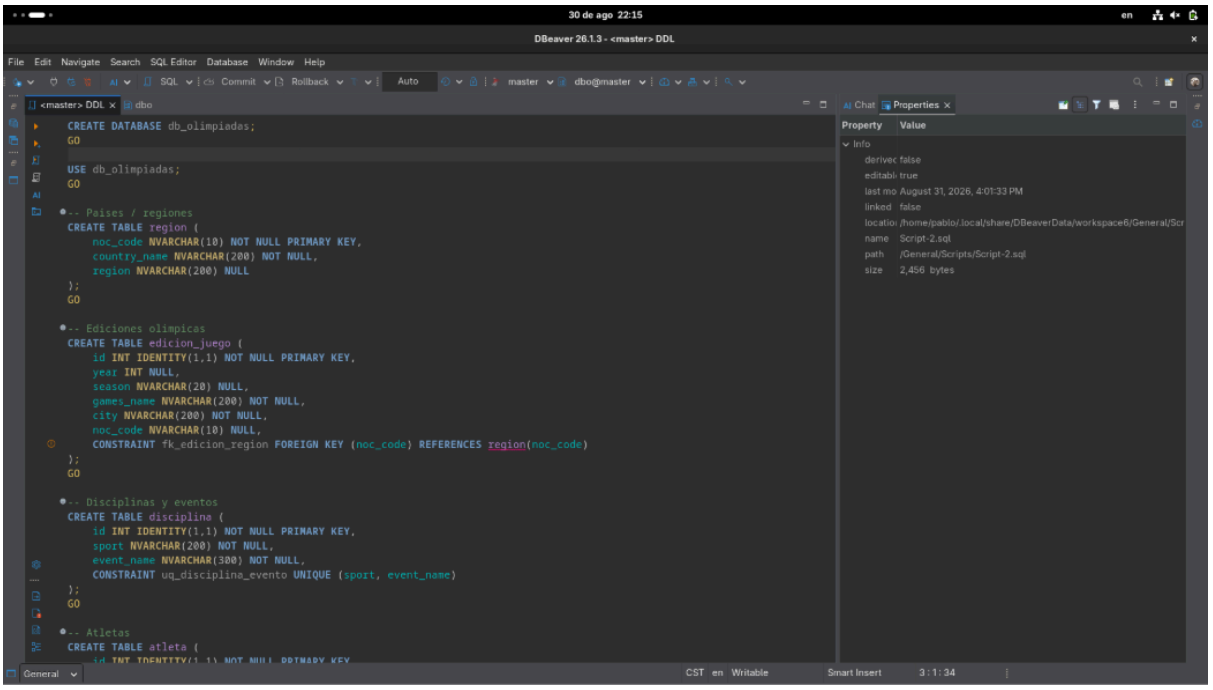
Participacion

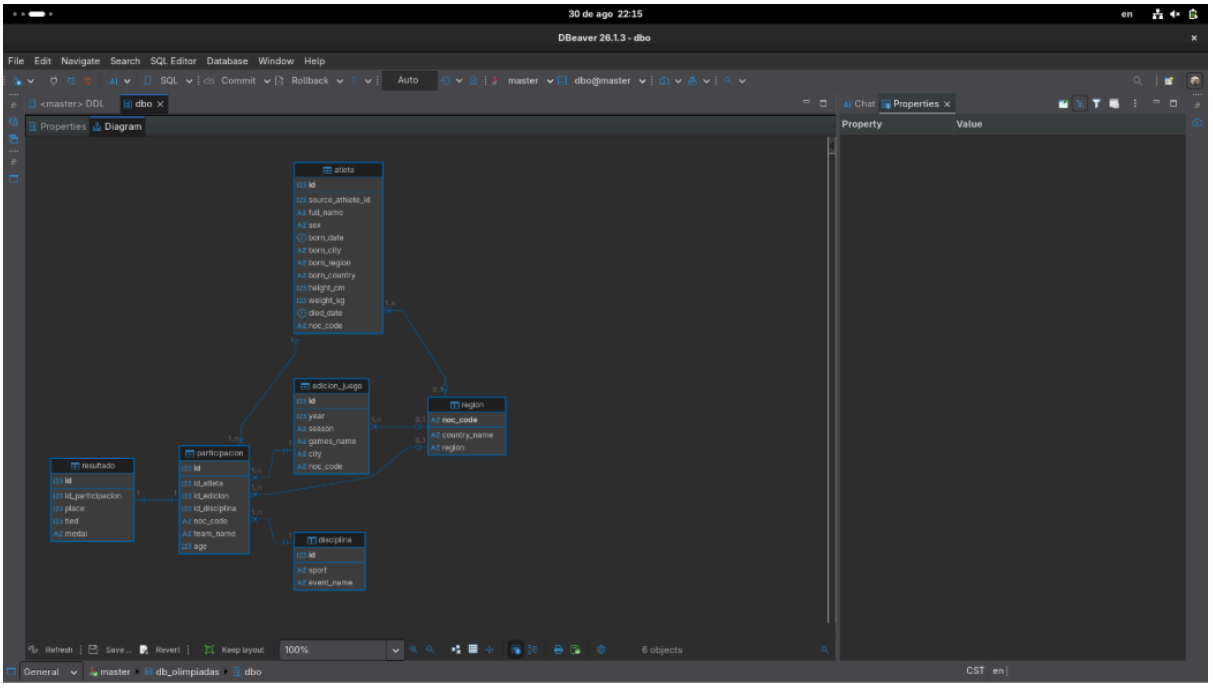
- PK: id
- FK: id_atleta
- FK: id_edicion
- FK: id_disciplina
- FK: noc_code
- team_name
- age

Resultado

- PK: id
- FK: id_participacion
- place
- tied
- medal

DDL modelo inicial





Primer diagrama E-R

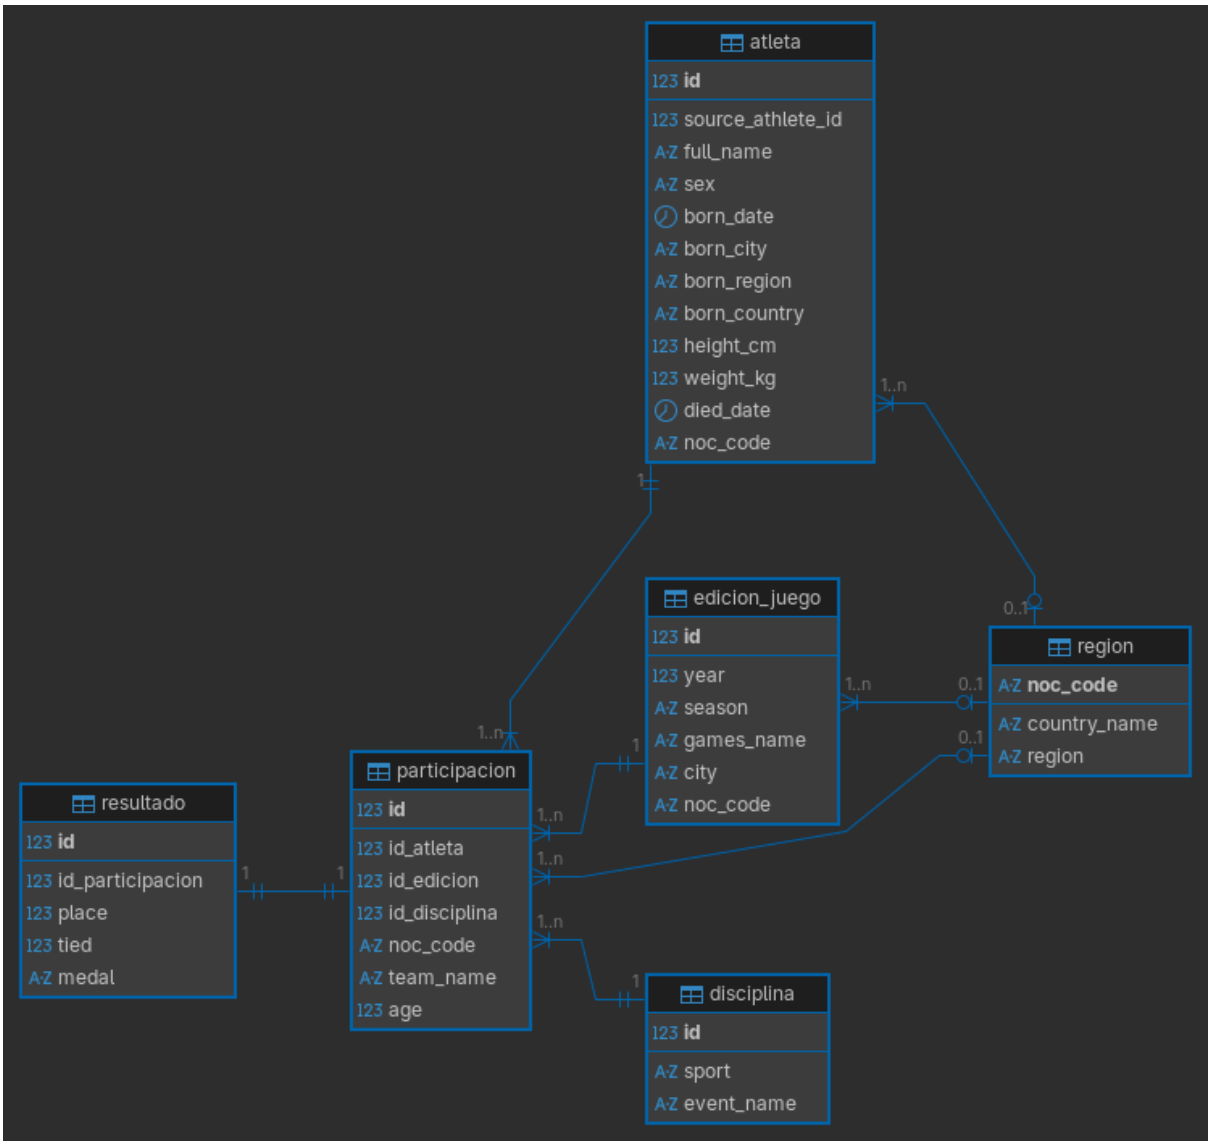
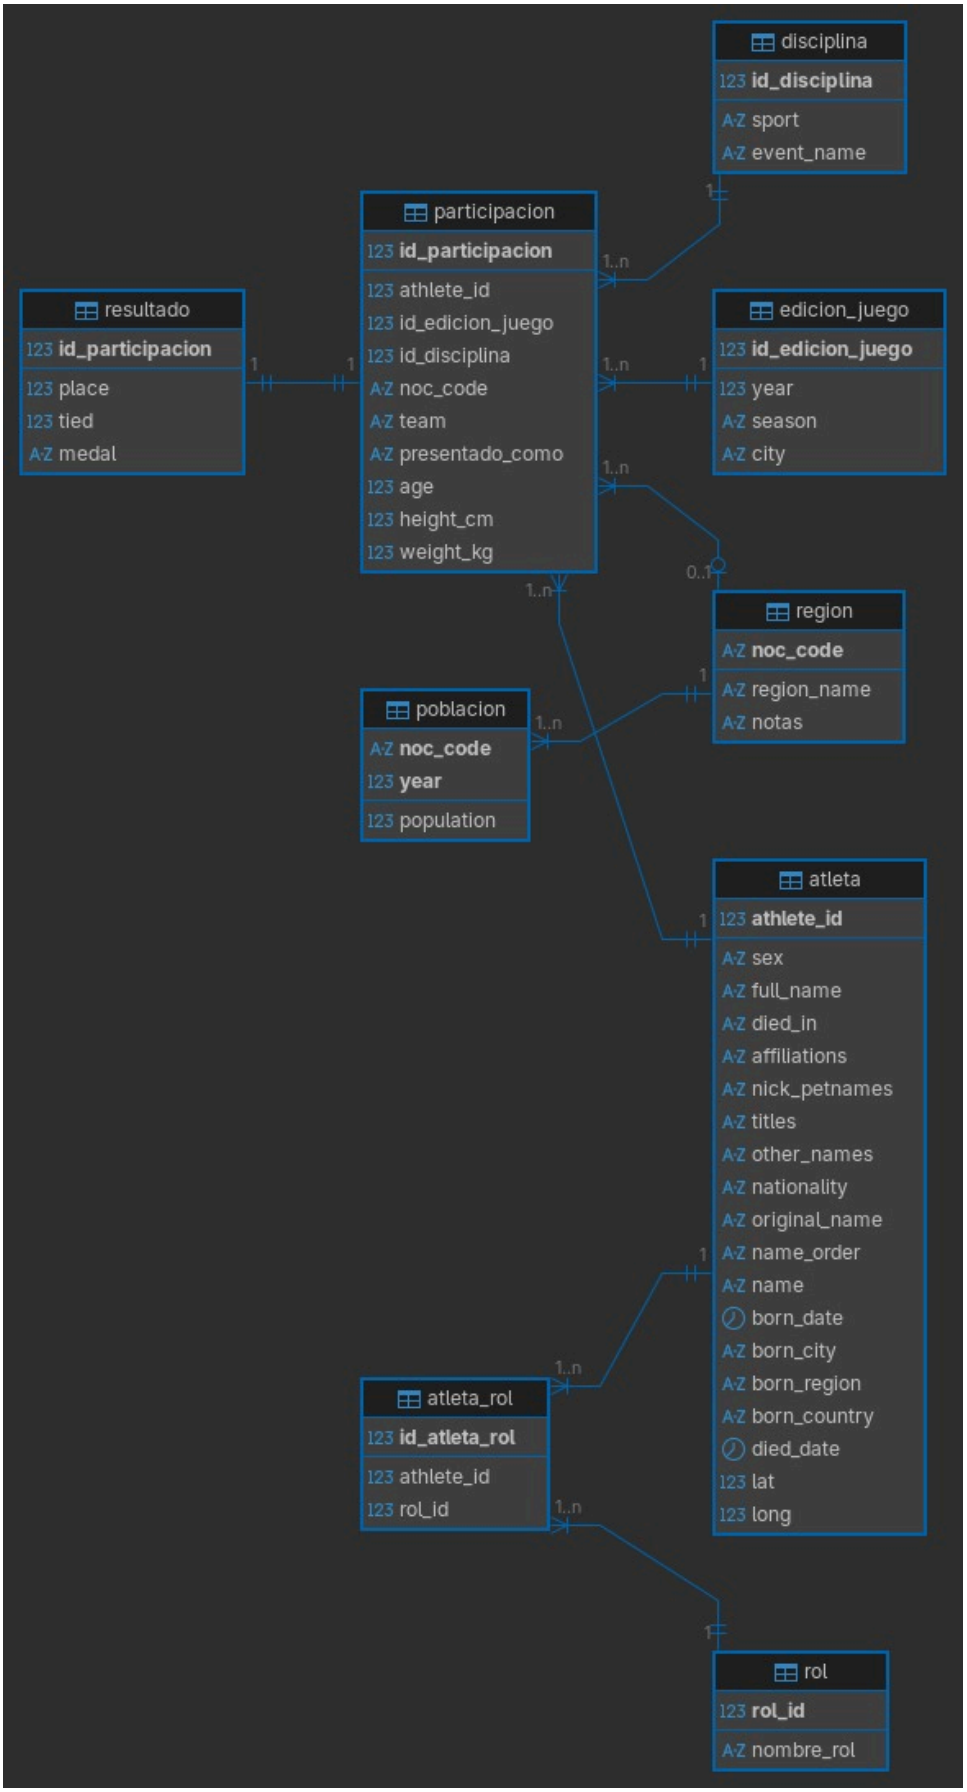


Diagrama E-R final



Preparación de los datos para importación:

Se utilizó pandas de Python para el análisis de los datos. Los recursos utilizados fueron la documentación oficial para varias funciones y algunas consultas con la IA que serán mostradas por medio de imágenes.

Para unificar los resultados de todas las fuentes, se utilizó el archivo results.py para combinar results de ambas fuentes del repositorio de GitHub. Esto permitió cubrir vacíos posibles. Resultó en un archivo worked_datasets/resultsFull.csv.

A continuación, se utilizó worked_datasets/resultsFull.csv, datasets/athlete_events.csv, datasets/datalab_export_2026-08-31 18_07_14.csv y datasets/olympics_dataset.csv para combinar las fuentes en un solo archivo unificado. El código sigue estos pasos para la unificación y limpieza de los datos:

- Normalizar y estandarizar los registros para tomar mejores coincidencias
  - Datalab export: Tiene archivos con cadenas “null” como string y nombres en minúscula, por lo que se aplica pd.NA a las cadenas “null” y los nombres en mayúscula. Además de pasar a numéricos los campos numéricos en la fuente de información.
  - Olympics_dataset: Utiliza “no medal” en vez de pd.NA, por lo que se aplica N/A.
  - Todas los datasets: Se normaliza el texto como string y se quitan los espacios
- Se combinan datalab_export y athlete_events, pues tienen información parecida, por medio de un concat.
- Se enriquece la tabla generada en el paso anterior, ya que se agrupa por (Nombre, Año, NOC, Temporada) para aplicar el primer valor que se tenga de edad y ciudad en caso de que haya registros con iguales campos del filtro, pero sin los datos de ciudad o edad.
- Se hace merge del dataset del archivo resultsFull.csv con el dataset del paso anterior, por medio de los campos (Nombre, Año, NOC, Temporada) en ambos datasets (left join; se mantiene la información de resultsFull como prioritaria). Se le quitan las columnas del segundo dataset debido al merge.
- Se aplica height y weight por medio del archivo bios.csv al resultado anterior.
- En caso de que no se haya llenado el dato, se aplica height y weight por medio de un dataset concatenado entre datasets/athlete_events.csv y datasets/datalab_export_2026-08-31 18_07_14.csv si el dato estaba vacío, no se reemplaza.
- Se aplica ciudad y equipo al dataset resultado por medio de datasets/olympics_dataset.csv en caso de que no se tuviera un equipo o ciudad en alguno de los registros con uno o ambos de los campos vacíos.
- Se seleccionan los campos finales a estar en el archivo resultsUnificado.csv, se aplica al resultado y se exporta a worked_datasets/resultsUnificado.csv.

Tabla_rol.csv:

Se creó un código en pandas también para crear una tabla roles según el campo rol del archivo biosComplejo.csv, además de asignar uno o varios roles a cada deportista en un nuevo archivo llamado bios_normalizado1.csv. Se creó un archivo tabla_rol.csv conteniendo

todos los roles del archivo biosComplejo.csv. El archivo de Python se llama roles.py. Se aprovecha para exportar un biosNormalizado1.csv

Tabla_atletas.csv:

Para la creación del archivo csv de atleta se utilizaron los archivos bios.csv, biosNormalizado1.csv y bios_locs.csv. Los campos que se utilizaron como primera elección en cada archivo son:

Bios.csv:

- Name
- Born_date
- Born_city
- Born_region
- Born_country
- Died_date

Bios_locs.csv:

- Lat
- Long

BiosNormalizado1.csv:

- Sex
- Full name
- Died_in
- Affiliations
- Nick/petnames
- Title(s)
- Other names
- Nationality
- Original name
- Name order
- Rol_id

Nota: No se incluye el NOC deliberadamente, ya que existen datos de algunos deportistas con NOC diferentes entre participaciones o con diferente sintaxis en su declaración. Tampoco se incluye weight ni height, ya que son datos que pueden cambiar de participación en participación. Esos se incluyen en la tabla participación.

Tabla_atleta_rol:

Tabla intermedia entre atleta y rol, ya que muchos atletas pueden tener muchos roles, se utiliza para romper la relación N:N. Se crea en el mismo archivo de atletas.py.

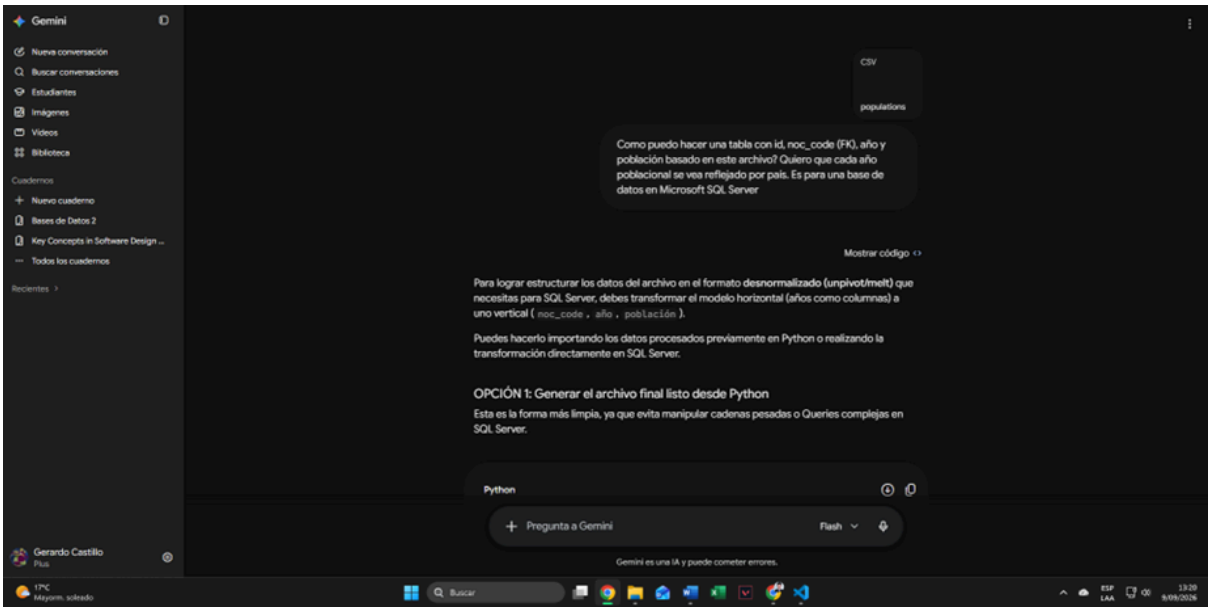
Tabla_edicion_juego.csv:

Se lee datasets/resultsUnificado.csv, se agrupa por año y tipo, se aplica el primer valor de la ciudad para evitar N/A en los registros, se ordenan los valores. Se aplica un índice único para cada valor. Se exporta a csv.

Tabla_disciplina.csv:

Se lee datasets/resultsUnificado.csv, se selecciona la disciplina y evento, se eliminan duplicados, se ordena y se exporta.

Tabla_poblaciones.csv:

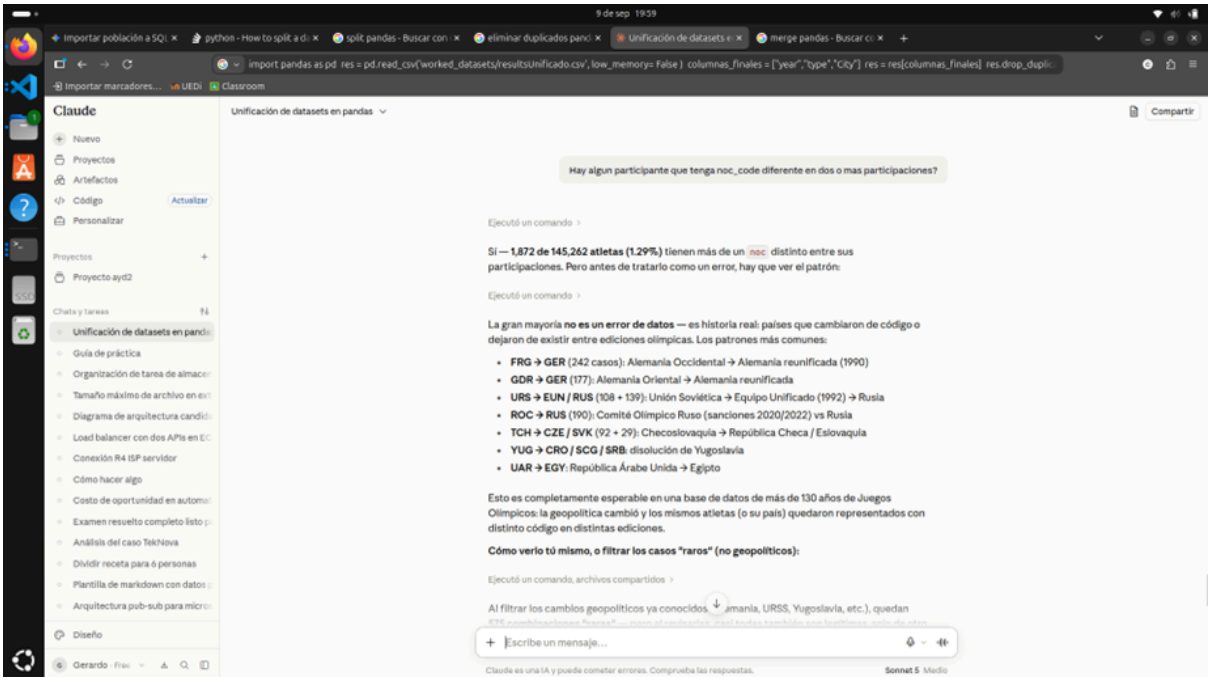


Se preguntó a Gemini cómo utilizar el archivo populations.csv para crear una tabla **poblaciones**, donde se coloque el NOC, año y el número poblacional.

Se utilizó parte del código de pandas proveído por Gemini. Se utiliza un melt que agrupa todos los valores numéricos y se le aplican tipos de datos respectivos. Se exporta a csv.

Tabla_participación y tabla_resultado:

Al ser una relación 1:1 en el diagrama E-R, se aplica un merge de la tabla_edicion_juego con resultsUnificado, así se obtiene el id de la edición y se descartan los demás valores de la tabla_edicion_juego. Lo mismo se hace para disciplina. Del resultado derivado se separa otra tabla llamada resultado, donde se tiene la medalla, lugar y si se empató. Se incluyó deliberadamente noc_code, height y weight luego de consultar con la IA sobre el dataset.



Tabla_nocs:

Se mantiene el noc_code del dataset.

Decisiones de diseño — DDL

Resumen de las decisiones tomadas al construir el script de creacion de la base de datos (staging + modelo relacional final).

- Motor: SQL Server 2022, con patron ELT (staging en NVARCHAR(MAX) + migracion limpia al modelo final) para no perder filas por errores de tipo (regla de “eliminacion minima”).
- Script idempotente: hace DROP de todos los objetos en orden de dependencias antes de crearlos, para poder re-ejecutarlo sin errores durante el desarrollo.
- region usa PK natural noc_code (no se creo un id sustituto); se agrego la columna notas para no perder noc_regions.notes.
- edicion_juego integra los datos de sede (city, noc_code) porque una sede siempre pertenece a una sola edicion (relacion 1:1 real); year es NULL porque ~2,601 filas de la fuente no traen anio.
- atleta usa id subrogado IDENTITY + source_athlete_id (trazabilidad), porque cada fuente trae su propio id independiente; se agregaron los campos nuevos pedidos (used_name, nombre_original, otros_nombres, orden_nombre, apodos, titulos, afiliaciones, nacionalidad, latitud, longitud).
- resultado tiene relacion 1:1 con participacion (FK UNIQUE); place se guarda como texto (NVARCHAR) porque la fuente trae valores no numericos (“DNF”, “AC”, “=3”).
- poblacion usa PK compuesta (noc_code, anio); roles y participacion_roles resuelven la relacion N:M de roles dentro de una participacion.
- CHECK tolerantes (sex, season y medal aceptan NULL en vez de forzar un catalogo cerrado) e indices creados pensando en los parametros de busqueda de los Stored Procedures (nombre, pais, anio).

Proceso de carga — DDL

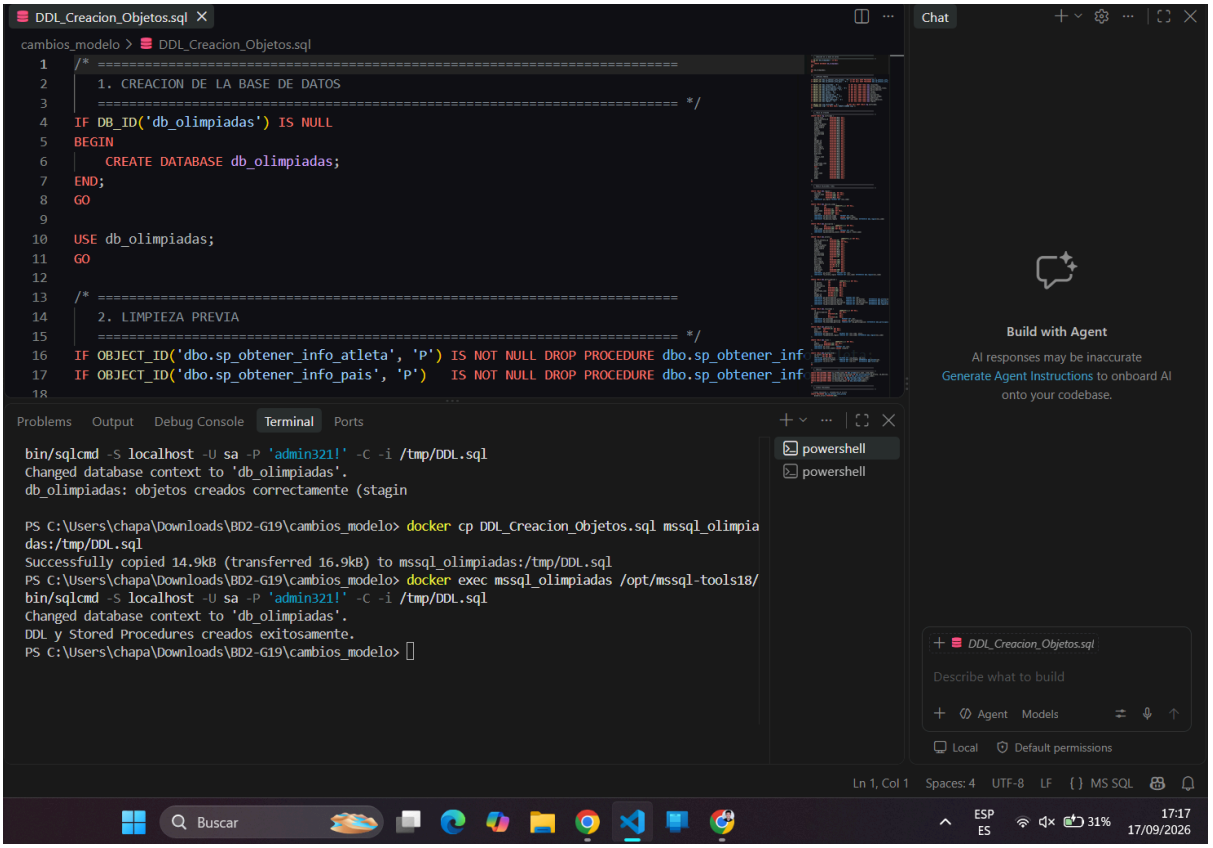
- Docker instalado y corriendo
- Python3 con pandas y pymssql con “pip install pandas pymssql”
- Software DBeaver

Se levanta SQL Server a través de un contenedor de docker:

docker run -e "ACCEPT_EULA=Y" -e "MSSQL_SA_PASSWORD=admin321!" -p 1433:1433 --name mssql_olimpiadas --restart unless-stopped -d mcr.microsoft.com/mssql/server:2022-latest

Nueva conexión → SQL Server:
Host: localhost
Port: 1433
Database/Instance: (vacío o "master")
Authentication: SQL Server Authentication
Username: sa
Password: admin321!

Se abre el archivo DDL_Creacion_Objetos.sql y se ejecuta en la conexión con la bd.



Decisiones de diseño — ETL de Carga

Resumen de las decisiones tomadas al construir el script que carga los tabla_*.csv reales hacia el modelo final.

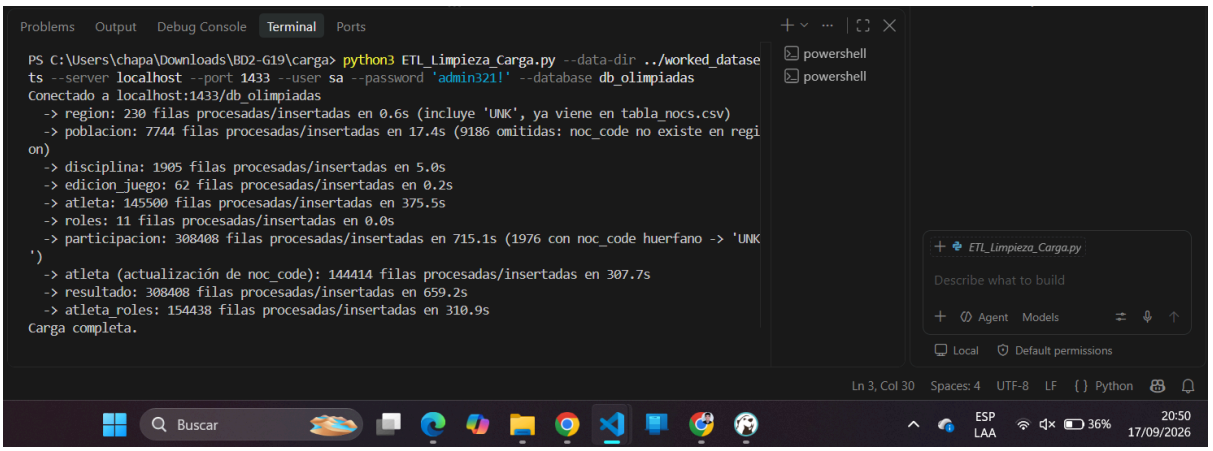
- Python (pandas + pymssql) en vez de BULK INSERT puro: se probo BULK INSERT nativo de SQL Server primero, pero en Linux maltrata los acentos UTF-8 (la opcion CODEPAGE no esta soportada, y la combinacion DATAFILETYPE='widechar' + FORMAT='CSV' tampoco); Python con el modulo csv de pandas maneja UTF-8, comillas y comas embebidas de forma nativa y confiable.
- Orden de carga respeta las dependencias de llaves foraneas: region -> poblacion, disciplina, edicion_juego -> atleta -> roles -> participacion -> resultado -> atleta_roles.
- Los IDs de la fuente se preservan (SET IDENTITY_INSERT) en atleta, edicion_juego, disciplina, roles y participacion, en vez de generar IDs nuevos. Esto evita un mapeo adicional entre los tabla_*.csv y el modelo final, y mantiene trazabilidad 1:1 con la fuente.
- Transformaciones de limpieza aplicadas al insertar (no en el CSV original): sex 'Male'/'Female' -> 'M'/'F'; medal '' -> NULL; games_name se construye (year + season) porque tabla_edicion_juego.csv no la trae; los 3 valores especiales de season (Zappas Olympic Games, Intercalated Games, Equestrian Olympics) se conservan en vez de descartarse.
- Manejo de huerfanos sin romper la carga: noc_code de participacion que no existe en region cae a 'UNK'; filas de poblacion con noc_code no encontrado (codigos agregados del Banco Mundial como AFE/ARB) se omiten puntualmente y se reporta cuantas fueron.
- Mapeo de nombres de atleta sin perder información: la columna 'name' se asigna a full_name; 'Full name' (nombre ceremonial/completo) se guarda en used_name; y las variantes o nombres secundarios ('Other names') se almacenan en otros_nombres.
- Insercion en bloques de 5000 filas (executemany) por rendimiento, con commit por tabla y rollback automatico si una tabla falla, para no dejar la base a medio cargar.
- Verificado contra una base real con los ~935,000 registros de worked_datasets: conteos de filas correctos por tabla y casos de prueba coherentes (ej. el medallero de Michael Phelps calculado por el Stored Procedure da 23 oros, 3 platas, 2 bronces = 28 medallas, que coincide con su record real).

Proceso de carga del ETL

Utilizando la estructura de carpetas del google drive, se utiliza:

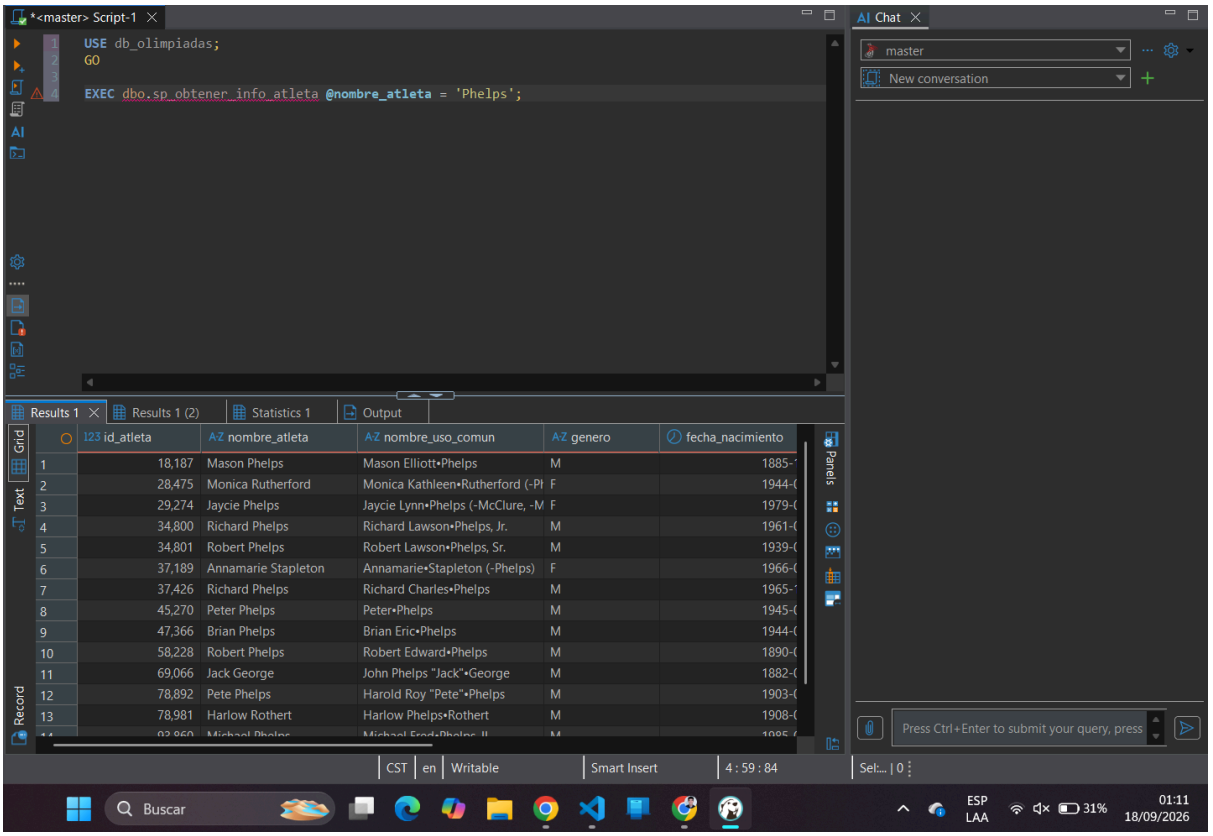
python3 ETL_Limpieza_Carga.py --data-dir ../worked_datasets --server localhost --port 1433 --user sa --password 'admin321!' --database db_olimpiadas

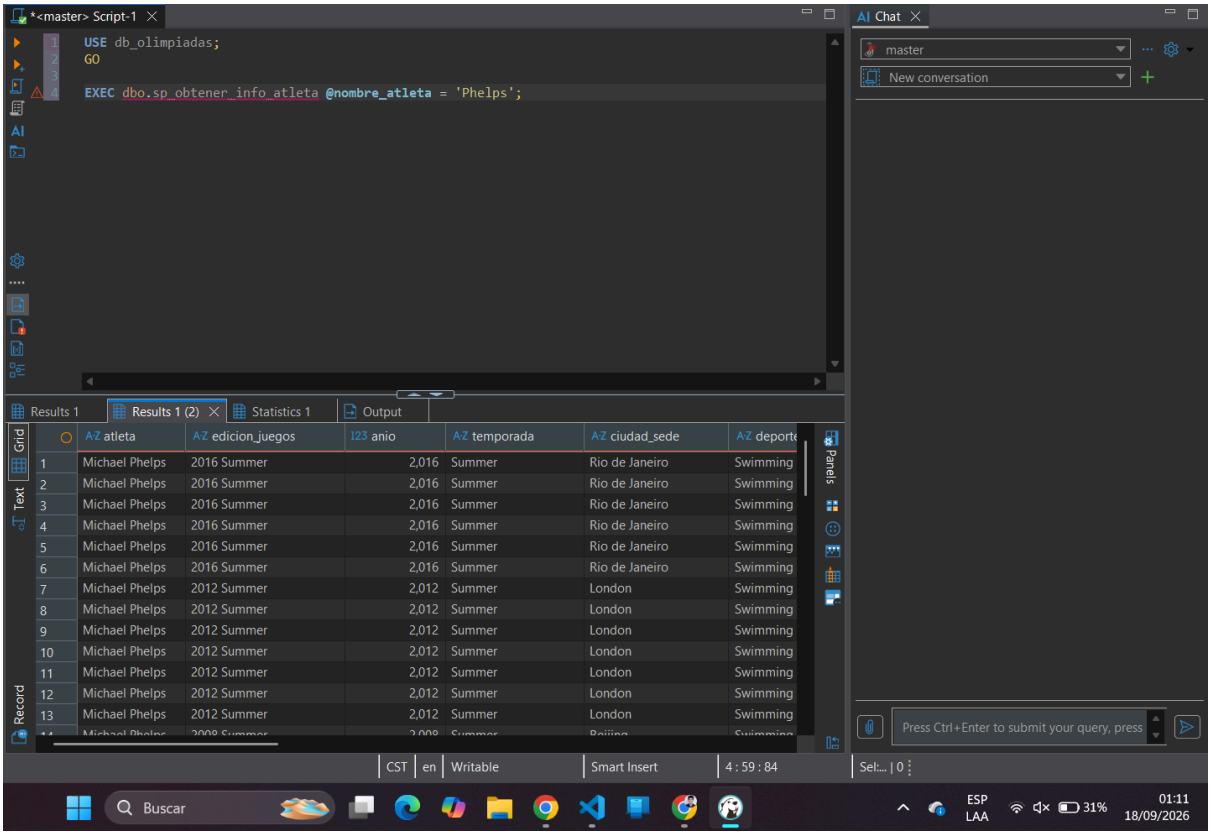
El resultado de ejecutar esto es:



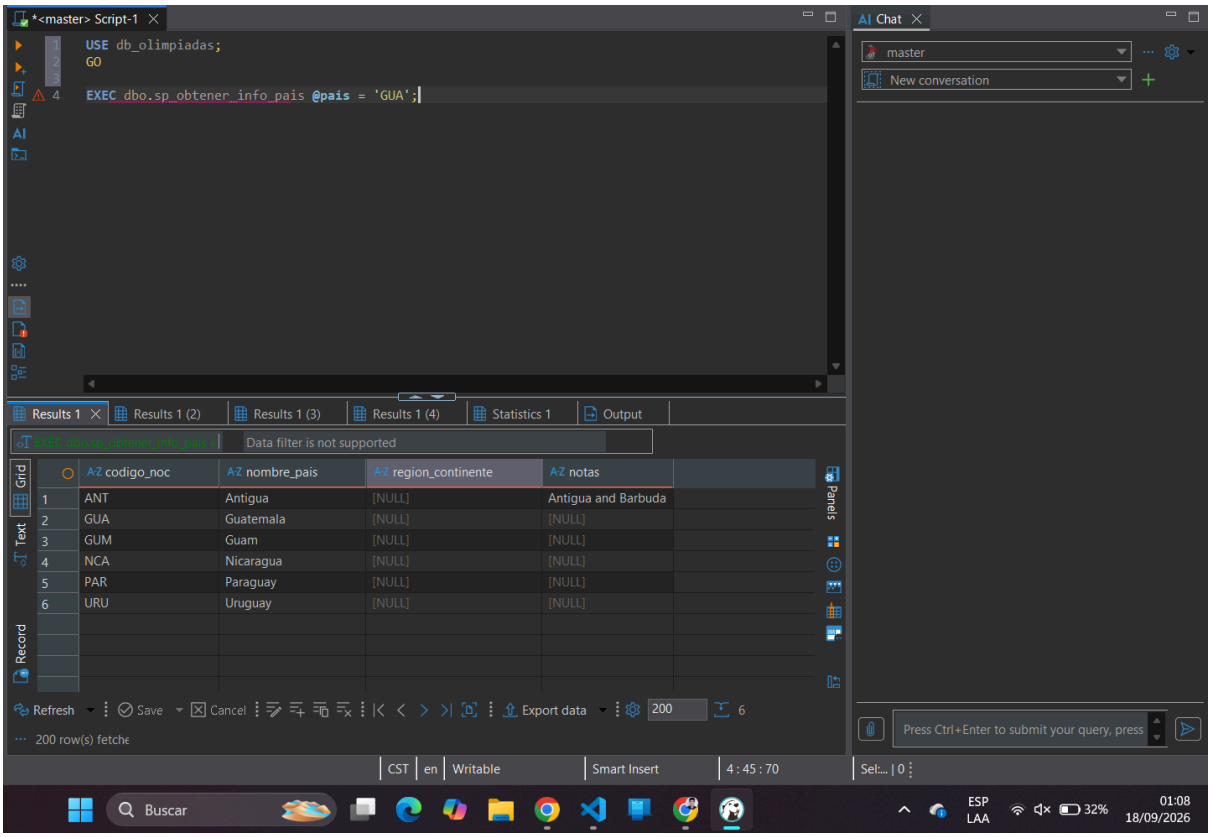
Resultados de los SP

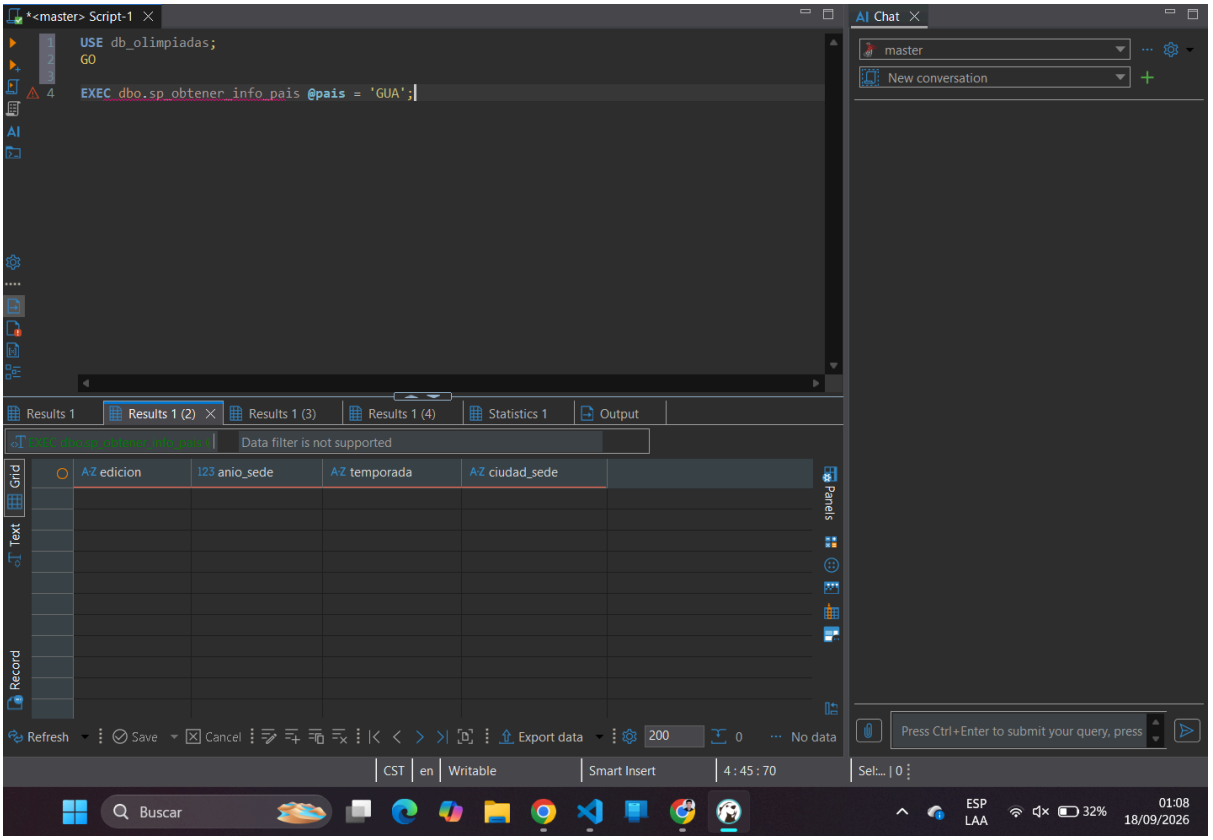
SP 1 - Búsqueda por atleta

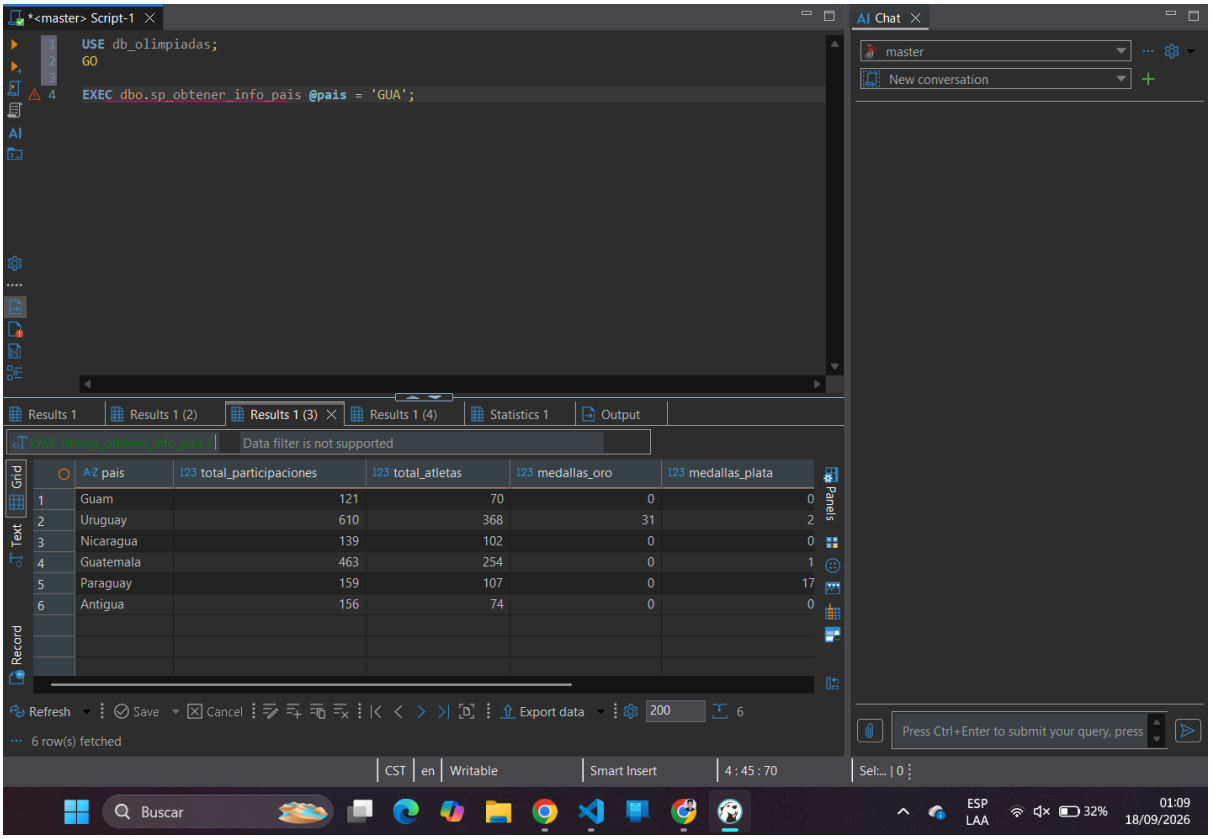


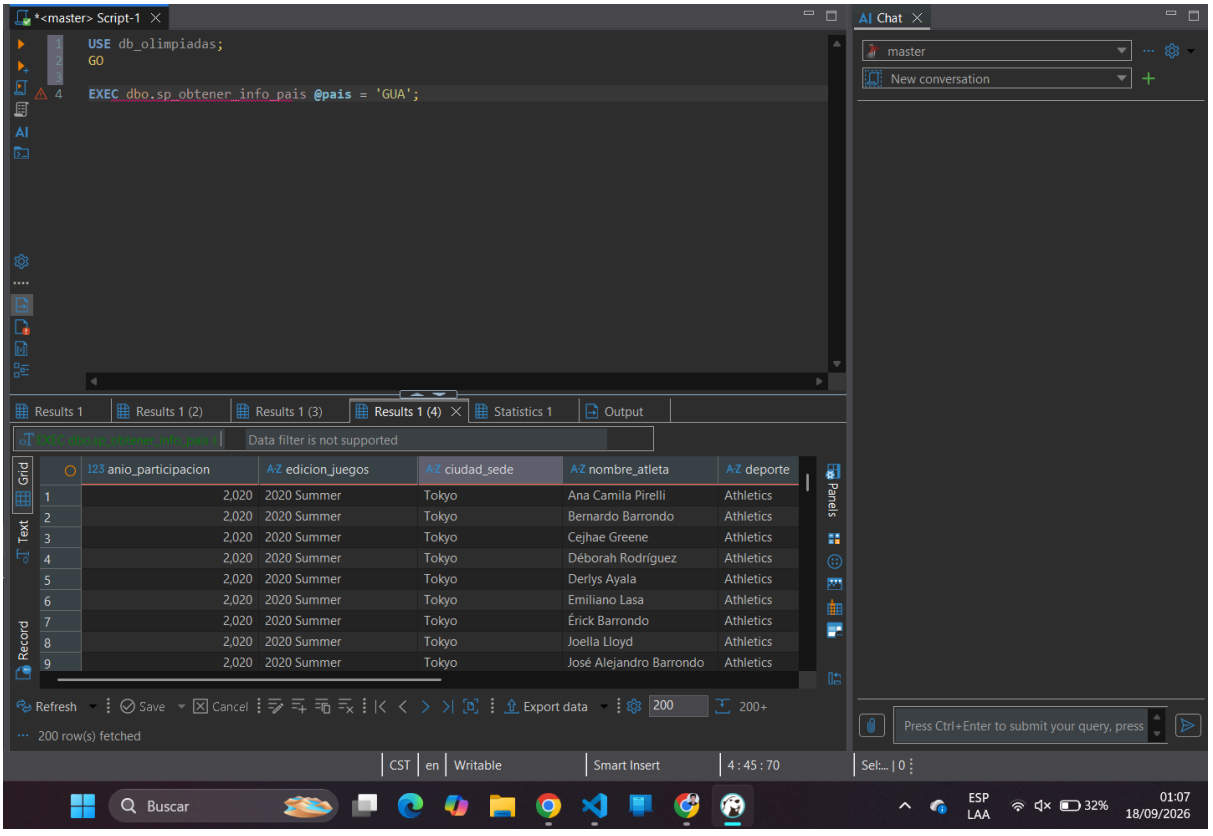

*<master> Script-1
USE db_olimpiadas;
GO
EXEC dbo.sp_obtener_info_atleta @nombre_atleta = 'Phelps';
AI Chat
master
New conversation
Results 1
Results 1 (2)
Statistics 1
Output
Grid
Text
Record
Panels
atleta
edicion_juegos
anio
temporada
ciudad_sede
deporte
1 Michael Phelps 2016 Summer 2,016 Summer Rio de Janeiro Swimming
2 Michael Phelps 2016 Summer 2,016 Summer Rio de Janeiro Swimming
3 Michael Phelps 2016 Summer 2,016 Summer Rio de Janeiro Swimming
4 Michael Phelps 2016 Summer 2,016 Summer Rio de Janeiro Swimming
5 Michael Phelps 2016 Summer 2,016 Summer Rio de Janeiro Swimming
6 Michael Phelps 2016 Summer 2,016 Summer Rio de Janeiro Swimming
7 Michael Phelps 2012 Summer 2,012 Summer London Swimming
8 Michael Phelps 2012 Summer 2,012 Summer London Swimming
9 Michael Phelps 2012 Summer 2,012 Summer London Swimming
10 Michael Phelps 2012 Summer 2,012 Summer London Swimming
11 Michael Phelps 2012 Summer 2,012 Summer London Swimming
12 Michael Phelps 2012 Summer 2,012 Summer London Swimming
13 Michael Phelps 2012 Summer 2,012 Summer London Swimming
Press Ctrl+Enter to submit your query, press
CST
en
Writable
Smart Insert
4 : 59 : 84
Sel:... | 0
Buscar
ESP
LAA
31%
01:11
18/09/2026

SP 2 - Busqueda por país






*<master> Script-1
USE db_olimpiadas;
GO
EXEC dbo.sp_obtener_info_pais @pais = 'GUA';
AI Chat
master
New conversation
Results 1
Results 1 (2)
Results 1 (3)
Results 1 (4)
Statistics 1
Output
Data filter is not supported
Grid
Text
Record
Panels
pais
total_participaciones
total_atletas
medallas_oro
medallas_plata
1 Guam 121 70 0 0
2 Uruguay 610 368 31 2
3 Nicaragua 139 102 0 0
4 Guatemala 463 254 0 1
5 Paraguay 159 107 0 17
6 Antigua 156 74 0 0
Refresh
Save
Cancel
Export data
200
6
6 row(s) fetched
Press Ctrl+Enter to submit your query, press
CST
en
Writable
Smart Insert
4 : 45 : 70
Sel:... | 0
Buscar
ESP
LAA
32%
01:09
18/09/2026


*<master> Script-1
USE db_olimpiadas;
GO
EXEC dbo.sp_obtener_info_pais @pais = 'GUA';
AI Chat
master
New conversation
Results 1
Results 1 (2)
Results 1 (3)
Results 1 (4)
Statistics 1
Output
Data filter is not supported
Grid
Text
Record
Panels
anio_participacion
edicion_juegos
ciudad_sede
nombre_atleta
deporte
1 2,020 2020 Summer Tokyo Ana Camila Pirelli Athletics
2 2,020 2020 Summer Tokyo Bernardo Barrondo Athletics
3 2,020 2020 Summer Tokyo Cejhae Greene Athletics
4 2,020 2020 Summer Tokyo Déborah Rodríguez Athletics
5 2,020 2020 Summer Tokyo Derlys Ayala Athletics
6 2,020 2020 Summer Tokyo Emiliano Lasa Athletics
7 2,020 2020 Summer Tokyo Érick Barrondo Athletics
8 2,020 2020 Summer Tokyo Joella Lloyd Athletics
9 2,020 2020 Summer Tokyo José Alejandro Barrondo Athletics
Refresh
Save
Cancel
Export data
200
200+
200 row(s) fetched
Press Ctrl+Enter to submit your query, press
CST
en
Writable
Smart Insert
4 : 45 : 70
Sel:... | 0
Buscar
ESP
LAA
32%
01:07
18/09/2026